① 基本知识

由已知的样本值推断总体的情况(总体分布F(x)的性质)

样本是联系二者的桥梁。总体分布决定了样本取值的概率规律，即样本取到样本值的规律，因而可以由样本值去推断总体。

样本均值 $\bar{X}=\frac{1}{n}\sum_{i=1}^{n}X_i$ → 反映了总体均值的信息

样本方差 $S^2=\frac{1}{n-1}\sum_{i=1}^{n}(X_i-\bar{X})^2$ → 反映了总体方差的信息

样本k阶原点矩 $A_k=\frac{1}{n}\sum_{i=1}^{n}X_i^k$ → 反映了总体k阶矩的信息

样本k阶中心矩 $B_k=\frac{1}{n}\sum_{i=1}^{n}(X_i-\bar{X})^k$, $k=1,2,\cdots$ → 反映了总体k阶中心矩的信息

对应的观察值公式差不多，仅当大写改小写。

$$\frac{1}{n-1}\sum_{i=1}^{n}(X_i-\bar{X})^2=\frac{1}{n-1}\left(\sum_{i=1}^{n}X_i^2-n\bar{X}^2\right)$$

1. χ^2分布

定义：设$X_1\cdots X_n$相互独立，都服从标准正态分布$N(0,1)$，则称随机变量 $\chi^2=X_1^2+\cdots+X_n^2$ 所服从的分布为自由度为n的χ^2分布，记为 $\chi^2\sim\chi^2(n)$

χ^2分布的概率密度为

$$f(y)=\begin{cases}\frac{1}{2^{\frac{n}{2}}\Gamma(n/2)}y^{\frac{n}{2}-1}e^{-\frac{y}{2}}, & y>0\\ 0, & else\end{cases}$$

其中$\Gamma(\frac{n}{2})$是函数$\Gamma(s)=\int_0^{\infty}e^{-t}t^{s-1}dt$ $(s>0)$在$s=\frac{n}{2}$处的值。

性质1. 设$\chi^2\sim\chi^2(n)$ 则$E(\chi^2)=n$ $D(\chi^2)=2n$.

性质2. 设$\chi_1^2\sim\chi^2(n_1)$ $\chi_2^2\sim\chi^2(n_2)$且χ_1^2与χ_2^2相互独立，则

$\chi_1^2+\chi_2^2\sim\chi^2(n_1+n_2)$

2. t分布

定义：设$X\sim N(0,1)$ $Y\sim\chi^2(n)$且X与Y相互独立，则称变量$t=\frac{X}{\sqrt{Y/n}}$所服从的分布为自由度为n的t分布，记为$t\sim t(n)$。t的概率密度为

$$h(t)=\frac{\Gamma[(n+1)/2]}{\Gamma[n/2]\sqrt{n\pi}}\left(1+\frac{t^2}{n}\right)^{-\frac{n+1}{2}}$$

3. F分布

定义：设$X\sim\chi^2(n_1)$ $Y\sim\chi^2(n_2)$ X与Y相互独立，则称统计量$F=\frac{X/n_1}{Y/n_2}$服从自由度为n_1及n_2的F分布，n_1称为第一自由度，n_2称为第二自由度，记作$F\sim F(n_1,n_2)$

由定义：$\frac{1}{F}=\frac{Y/n_2}{X/n_1}\sim F(n_2,n_1)$

若$X\sim F(n_1,n_2)$ 则X的概率密度为

$$\psi(x)=\begin{cases}\frac{\Gamma(\frac{n_1+n_2}{2})}{\Gamma(\frac{n_1}{2})\Gamma(\frac{n_2}{2})}(\frac{n_1}{n_2})(\frac{n_1}{n_2}x)^{\frac{n_1}{2}-1}(1+\frac{n_1}{n_2}x)^{-\frac{n_1+n_2}{2}} & ,x\geqslant 0\\ 0 & ,x<0\end{cases}$$

4. 上α分位点.

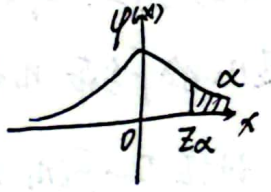
定义：设随机变量X的概率密度为$f(x)$对于任意给定的α $(0<\alpha<1)$若存在实数x_α使得

$$P\{X\geqslant x_\alpha\}=\int_{x_\alpha}^{+\infty}f(x)dx=\alpha.$$

则称点x_α为该概率分布的上α分位点.

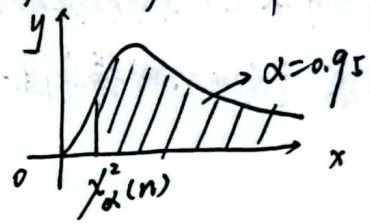
对标准正态分布变量$Z\sim N(0,1)$和给定α. 上α分位数是由

$$P\{Z\geqslant z_\alpha\}=\int_{z_\alpha}^{+\infty}\frac{1}{\sqrt{2\pi}}e^{-\frac{t^2}{2}}dt=\alpha \quad 即\ P\{Z<z_\alpha\}=1-\alpha \quad \Phi(z_\alpha)=1-\alpha.$$



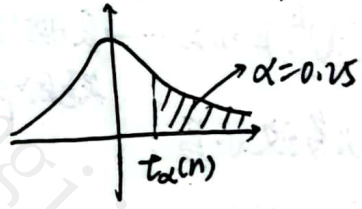
χ^2分布的上α分位点.

对给定的概率α，$0<\alpha<1$ 称满足条件$\int_{\chi^2_\alpha(n)}^{\infty}f_n(y)dy=\alpha$的点$\chi^2_\alpha(n)$为$\chi^2(n)$分布的上$\alpha$分位数



t分布的上α分位点.

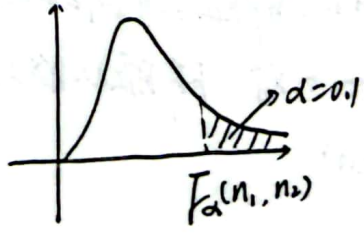
对给定的α，$0<\alpha<1$ 称满足条件$\int_{t_\alpha(n)}^{\infty}f(t,n)dt=\alpha$的点$t_\alpha(n)$为$t(n)$分布上的上$\alpha$分位数，$t_{1-\alpha}(n)=-t_\alpha(n)$



F分布的上α分位点.

对给定的α，$0<\alpha<1$ 称满足条件$\int_{F_\alpha(n_1,n_2)}^{\infty}f(x;n_1,n_2)dx=\alpha$的点$F_\alpha(n_1,n_2)$为$F(n_1,n_2)$分布的上$\alpha$分位数

$$F_{1-\alpha}(n_1,n_2)=\frac{1}{F_\alpha(n_2,n_1)}$$



Vx: shulitong1206

定理1. 设 $X_1 \cdots X_n$ 是取自正态总体 $N(\mu, \sigma^2)$ 的样本

(1) 样本均值 $\bar{X} \sim N(\mu, \frac{\sigma^2}{n})$

(2) 样本均值 $\bar{X}$ 与样本方差 S^2 相独立.

(3) 随机变量 $\frac{(n-1)S^2}{\sigma^2} = \frac{\sum_{i=1}^{n}(X_i-\bar{X})^2}{\sigma^2} \sim \chi^2(n-1)$. → 只需知道 $n-1$ 个 X_i 就可得 $\sum(X_i-\bar{X})^2$

$$\frac{\sum_{i=1}^{n}(X_i-\mu)^2}{\sigma^2} \sim \chi^2(n)$$

定理2 设 $X_1 \cdots X_n$ 是取自正态总体 $N(\mu, \sigma^2)$ 的样本. $\bar{X}$ 和 S^2 分别为样本均值和样本方差. 则有

$$\frac{\bar{X}-\mu}{S/\sqrt{n}} \sim t(n-1)$$

定理3 设 $X \sim N(\mu_1, \sigma^2)$ $Y \sim N(\mu_2, \sigma^2)$ 且 X 与 Y 独立. $X_1 \cdots X_{n_1}$ 是取自 X 的样本. $Y_1 \cdots Y_{n_2}$ 是取自 Y 的样本. $\bar{X}$ 和 $\bar{Y}$ 分别是这两个样本的样本均值. S_1^2 和 S_2^2 分别是这两个样本的样本方差. 则有

$$\frac{\bar{X}-\bar{Y}-(\mu_1-\mu_2)}{\sqrt{\frac{(n_1-1)S_1^2+(n_2-1)S_2^2}{n_1+n_2-2}}\sqrt{\frac{1}{n_1}+\frac{1}{n_2}}} \sim t(n_1+n_2-2)$$

定理4 设 $X \sim N(\mu_1, \sigma_1^2)$ $Y \sim N(\mu_2, \sigma_2^2)$ 且 X 与 Y 独立. $X_1 \cdots X_{n_1}$ 是取自 X 的样本. $Y_1 \cdots Y_{n_2}$ 是取自 Y 的样本. $\bar{X}$ 和 $\bar{Y}$ 分别是这两个样本的样本均值. S_1^2 和 S_2^2 分别是这两个样本的样本方差. 则有

$$\frac{S_1^2/\sigma_1^2}{S_2^2/\sigma_2^2} \sim F(n_1-1, n_2-1)$$

说明: 设 $X \sim N(\mu_1, \sigma_1^2)$ $Y \sim N(\mu_2, \sigma_2^2)$ 且 X 与 Y 独立. $X_1 \cdots X_{n_1}$ 是取自 X 的样本. $Y_1 \cdots Y_{n_2}$ 是取自 Y 的样本. $\bar{X}$ 和 $\bar{Y}$ 分别是这两个样本的样本均值. σ_1^2 和 σ_2^2 已知时.

$$\frac{(\bar{X}-\bar{Y})-(\mu_1-\mu_2)}{\sqrt{\frac{\sigma_1^2}{n_1}+\frac{\sigma_2^2}{n_2}}} \sim N(0,1).$$

设总体 X 的均值 μ, 方差 σ^2 存在, $(X_1 \cdots X_n)$ 是取自总体 X 的样本. $\bar{X}$. S^2 为样本均值和样本方差.

$$E(\bar{X}) = E[\frac{1}{n}\sum_{i=1}^{n}X_i] = \frac{1}{n}\sum_{i=1}^{n}E(X_i) = \mu$$

$$D(\bar{X}) = D[\frac{1}{n}\sum_{i=1}^{n}X_i] = \frac{1}{n^2}\sum_{i=1}^{n}D(X_i) = \frac{\sigma^2}{n}$$

$$E(S^2) = E[\frac{1}{n-1}\sum_{i=1}^{n}(X_i-\bar{X})^2] = \frac{1}{n-1}E[\sum_{i=1}^{n}X_i^2 - n\bar{X}^2] = \sigma^2$$

Visit skylitong11666

$$Cov(X_1, \bar{X}) = Cov(X_1, \frac{1}{n}\sum_{i=1}^{n} X_i) = \frac{1}{n} D(X_1) = \frac{\sigma^2}{n}$$

$$\rho_{X_1, \bar{X}} = \frac{Cov(X_1, \bar{X})}{\sqrt{D(X_1) D(\bar{X})}} = \frac{\sigma^2/n}{\sqrt{\sigma^2/n \times \sigma^2}} = \frac{1}{\sqrt{n}}$$

Vx: shulitong11666

② 参数估计 — 矩估计、极大似然估计. 估计量的评选准则.

参数估计 — 一类总体分布的类型为已知, 而它的参数为未知. 根据所得样本对这些参数作出推断.

矩估计法: 记总体 k 阶矩为 $\mu_k = E(X^k)$

样本 k 阶矩为 $A_k = \frac{1}{n}\sum_{i=1}^{n} X_i^k$

则样本 k 阶矩 A_k 依概率收敛于总体 k 阶矩 μ_k.

以样本矩估计总体矩. 以样本矩函数估计总体矩函数.

步骤: 设总体的分布函数的形式已知. 待估参数为 $\theta_1 \cdots \theta_k$, 总体的前 k 阶矩存在.

(1) 求出总体的前 k 阶矩. 一般是这 k 个参数的函数, 记为:

$E(X^r) = \mu_r(\theta_1 \cdots \theta_k) \quad r = 1, \cdots k.$

样本 $X_1 \cdots X_n$ 的前 k 阶矩记为 $A_r = \frac{1}{n}\sum_{i=1}^{n} X_i^r \quad r = 1, 2 \cdots k$

(2) 令 $\mu_r(\theta_1 \cdots \theta_k) = \frac{1}{n}\sum_{i=1}^{n} X_i^r$, $r = 1, \cdots k$. $\theta_1 \cdots \theta_k$ 未知参数

(3) 解此方程组, 得 k 个统计量. $\begin{cases} \hat{\theta}_1 = \hat{\theta}_1(X_1 \cdots X_n) \\ \cdots \\ \hat{\theta}_k = \hat{\theta}_k(X_1 \cdots X_n) \end{cases}$ 作为未知参数的矩估计量

注: 可用中心矩代替原点矩.

极大似然估计

一般说, 若事件 A 发生的概率与参数 $\theta \in \Theta$ 有关, θ 取值不同, $P(A)$ 也不同, 则在记事件 A 发生的概率为 $P(A|\theta)$. 若一次试验, 事件 A 发生了, 可以认为此时 θ 值应是在 Θ 中使 $P(A|\theta)$ 达到最大的那一个. 这就是极大似然原理.

似然函数: $X_1 \cdots X_n$ 是取自总体 X 的样本. $x_1 \cdots x_n$ 是样本值.

1. X 是离散型总体. 其分布律为 $P\{X=x\} = p(x, \theta_1 \cdots \theta_k)$

其中 $\theta_1 \cdots \theta_k$ 为未知待估参数

则样本的联合分布律为

$$P\{X_1 = x_1, X_2 = x_2 \cdots X_n = x_n\} = p(x_1, \theta_1 \cdots \theta_k)\, p(x_2, \theta_1 \cdots \theta_k) \cdots p(x_k, \theta_1 \cdots \theta_k) = \prod_{i=1}^{n} p(x_i, \theta_1 \cdots \theta_k)$$

记 $L(\theta_1 \cdots \theta_k) = \prod_{i=1}^{n} p(x_i, \theta_1 \cdots \theta_k)$ (似然函数)

2. X 是连续型总体 其概率密度为 $f(x, \theta_1 \cdots \theta_k)$ 则称 $L(\theta_1 \cdots \theta_k) = \prod_{i=1}^{n} f(x_i, \theta_1 \cdots \theta_k)$ 为样本的似然函数.

求 $\hat{\theta}_i = \theta_i(x_1 \cdots x_k)$ 使 $L(\hat{\theta}_1, \cdots \hat{\theta}_k) = \max L(\theta_1 \cdots \theta_k)$

步骤 1) 由总体分布和所给样本, 求得似然函数

lxsklton@163.com

$L(\theta_1 \cdots \theta_k) = \prod_{i=1}^{n} f(x_i, \theta_1 \cdots \theta_k)$

(2) 求 $L(\theta_1 \cdots \theta_k)$ 的对数函数 $\ln L(\theta_1 \cdots \theta_k)$

(3) 解方程组

$$\begin{cases} \dfrac{\partial \ln L(\theta_1 \cdots \theta_k)}{\partial \theta_1} = 0 \\ \cdots \\ \dfrac{\partial \ln L(\theta_1 \cdots \theta_k)}{\partial \theta_k} = 0 \end{cases}$$

无偏性准则

由于未知参数 θ 的估计量 $\hat{\theta} = \hat{\theta}(X_1 \cdots X_n)$ 是随机变量，每次抽样后得到的 θ 的估计值不一定与真值 θ 相吻合，其误差为 $\hat{\theta} - \theta$，我们希望平均误差为零，即 $E(\hat{\theta} - \theta) = 0$.

定义：设 $\hat{\theta}$ 是未知参数 θ 的估计量，若 $E(\hat{\theta}) = \theta$，则称 $\hat{\theta}$ 是 θ 的无偏估计量.

若 $\lim_{n\to\infty} E(\hat{\theta}) = \theta$ 则称 $\hat{\theta}$ 是 θ 的渐近无偏估计量.

有效性准则.

设 $\hat{\theta}_1$ 和 $\hat{\theta}_2$ 都是 θ 的无偏估计量，即两个估计量 $\hat{\theta}_1$ 和 $\hat{\theta}_2$ 都围绕着 θ 波动，我们自然选择波动幅度小的那个.

定义：设 $\hat{\theta}_1 = \theta_1(X_1 \cdots X_n)$ $\hat{\theta}_2 = \theta_2(X_1 \cdots X_n)$ 都是总体参数 θ 的无偏估计量，且 $D(\hat{\theta}_1) < D(\hat{\theta}_2)$ 则 $\hat{\theta}_1$ 比 $\hat{\theta}_2$ 更有效

Rao-Cramer 不等式

若 $\hat{\theta}$ 是参数 θ 的无偏估计量，则 $D(\hat{\theta}) \geq \dfrac{1}{nE\left[\frac{\partial}{\partial\theta}\ln p(x,\theta)\right]^2} = D_0(\theta)$

其中 $p(x,\theta)$ 为总体 X 的分布律或概率密度，称 $D_0(\theta)$ 为方差的下界

当 $D(\hat{\theta}) = D_0(\theta)$ 时，称 $\hat{\theta}$ 为 θ 的达到方差下界的无偏估计量，此时称 $\hat{\theta}$ 为最有效的估计量. 简称有效估计量

均方误差准则.

定义 设 $\hat{\theta}$ 是参数 θ 的点估计，方差存在. 则称 $E(\hat{\theta}-\theta)^2$ 是估计量的均方误差，记为 $Mse(\hat{\theta})$

若 $\hat{\theta}$ 是 θ 的无偏估计，则有 $Mse(\hat{\theta}) = D(\hat{\theta})$

相合性准则

参数 θ 的估计量是样本的函数，与样本容量 n 有关，我们希望，样本容量 n 越大，估计量与参数 θ 的真值的偏差越小

定义：设 $\hat{\theta} = \hat{\theta}(X_1 \cdots X_n)$ 是总体参数 θ 的估计量，若对于任意的

Vx: shuitou2006

$\theta \in \Theta$，当 $n \to \infty$ 时，$\hat{\theta}$ 依概率收敛于 θ. 即对于任意正数 ε.
有 $\lim\limits_{n\to\infty} P(|\hat{\theta}-\theta| \geq \varepsilon) = 0$ 则称 $\hat{\theta}$ 是总体参数 θ 的相合(一致)
估计量

关于相合性的两个常用结论

1. 样本 k 阶矩是总体 k 阶矩的相合估计量
2. 设 $\hat{\theta}$ 是 θ 的无偏估计量且 $\lim\limits_{n\to\infty} D(\hat{\theta}) = 0$. 则 $\hat{\theta}$ 是 θ 的相合估计量

切比雪夫不等式

设随机变量 X 有数学期望 $E(X)=\mu$. 方差 $D(X)=\sigma^2$. 对任意 $\varepsilon>0$
有 $P\{|X-\mu| \geq \varepsilon\} \leq \frac{\sigma^2}{\varepsilon^2}$ 成立.

辛钦大数定律

设 $X_1 \cdots X_n$ 是相互独立的随机变量序列. 服从相同分布. 且具有有限的数学期望 μ. 则对任意的 $\varepsilon>0$ 有

$$\lim_{n\to\infty} P\left\{\left|\frac{1}{n}\sum_{i=1}^{n} X_i - \mu\right| < \varepsilon\right\} = 1$$

Li.shuli1ong1666

③ 区间估计

假设 $(X_1 \cdots X_n)$ 是总体 X 的一个样本，区间估计的方法是给出两个统计量 $\hat{\theta}_1 = \hat{\theta}_1(X_1 \cdots X_n)$，$\hat{\theta}_2 = \hat{\theta}_2(X_1 \cdots X_n)$，使区间 $[\hat{\theta}_1, \hat{\theta}_2]$ 以一定的可靠程度盖出 θ

定义 设总体 X 的分布函数 $F(x;\theta)$ 含有一个未知参数 θ，$(X_1 \cdots X_n)$ 是总体 X 的一个样本，对给定的值 $\alpha (0<\alpha<1)$，如果有两个统计量 $\hat{\theta}_L = \hat{\theta}_L(X_1 \cdots X_n)$ $\hat{\theta}_U = \hat{\theta}_U(X_1 \cdots X_n)$，使得

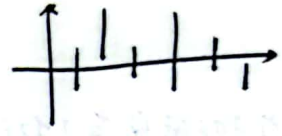
$$P\{\hat{\theta}_L(X_1 \cdots X_n) < \theta < \hat{\theta}_U(X_1 \cdots X_n)\} \geq 1-\alpha, \quad \forall \theta \in \Theta$$

则称随机区间 $(\hat{\theta}_L, \hat{\theta}_U)$ 是 θ 的双侧置信区间。称 $1-\alpha$ 为置信度，$\hat{\theta}_L$ 和 $\hat{\theta}_U$ 分别称为双侧置信下限和双侧置信上限。

如果 θ 的置信区间 $(\hat{\theta}_L, \hat{\theta}_U)$，满足：

$$P\{\hat{\theta}_L(X_1 \cdots X_n) < \theta < \hat{\theta}_U(X_1 \cdots X_n)\} = 1-\alpha. \quad \forall \theta \in \Theta$$

则置信区间 $(\hat{\theta}_L, \hat{\theta}_U)$ 的含义为：若反复抽样多次（每次样本量为 n），每个样本值确定一个区间 $(\hat{\theta}_L, \hat{\theta}_U)$，每个这样的区间或者包括 θ 的真值，或者不包括。按伯努利大数定律，在这些区间中，包含 θ 真值的约占 $100(1-\alpha)\%$



单侧置信限

定义 $P\{\hat{\theta}_L(X_1 \cdots X_n) < \theta\} \geq 1-\alpha \ (\forall \theta \in \Theta)$ 则称 $\hat{\theta}_L(X_1 \cdots X_n)$ 为 θ 的单侧置信下限。

$P\{\theta < \hat{\theta}_U(X_1 \cdots X_n)\} \geq 1-\alpha \ (\forall \theta \in \Theta)$ 则称 $\hat{\theta}_U(X_1 \cdots X_n)$ 为 θ 的单侧置信上限。

单、双侧置信区间的关系：

设 $\hat{\theta}_L = \hat{\theta}_L(X_1 \cdots X_n)$ 是参数 θ 的置信度为 $1-\alpha_1$ 的单侧置信下限，$\hat{\theta}_U = \hat{\theta}_U(X_1 \cdots X_n)$ 是参数 θ 的置信度为 $1-\alpha_2$ 的单侧置信上限，则 $(\hat{\theta}_L, \hat{\theta}_U)$ 是参数 θ 的置信度为 $1-\alpha_1-\alpha_2$ 的双侧置信区间。

定义 称置信区间 $[\hat{\theta}_L, \hat{\theta}_U]$ 的平均长度 $E(\hat{\theta}_U - \hat{\theta}_L)$ 为区间的精确度，并称 $\frac{1}{2}$ 区间的平均长度为置信区间的误差限。

Neyman 原则：在置信度达到一定的前提下，选取精确度尽可能高的区间。

枢轴量法

定义：设总体 X 有概率密度（相应分布律）$f(x;\theta)$，其中 θ 是待估的未知参数，并设 $x_1 \cdots x_n$ 是来自该总体的样本，称样本和未知参数 θ 的函数 $G(x_1 \cdots x_n;\theta)$ 为枢轴量，枢轴量的分布不依赖于任何未知参数

构造置信区间具体步骤

(1) 构造一个分布已知的枢轴量 $G(x_1 \cdots x_n;\theta)$

(2) 对连续型总体和给定的置信度 $1-\alpha$，设常数 $a<b$ 满足

$$P\{a<G(x_1 \cdots x_n;\theta)<b\}=1-\alpha.$$

(3) 若能从 $a<G(x_1 \cdots x_n;\theta)<b$ 得到等价的不等式

$$\hat{\theta}_L(x_1 \cdots x_n)<\theta<\hat{\theta}_U(x_1 \cdots x_n)$$

注：枢轴量的构造通常从参数 θ 的点估计 $\hat{\theta}$（极大似然、无偏、矩估计等）出发，根据 $\hat{\theta}$ 的分布进行改造而得.

步骤(2)中 a 与 b 常取 $P(G(x_1 \cdots x_n;\theta)\le a)=P(G(x_1 \cdots x_n;\theta)\ge b)=\alpha/2$.

正态总体下常见枢轴量

(1) 单个正态总体 $N(\mu,\sigma^2)$ 情形.

μ 的枢轴量 $\begin{cases}\dfrac{\sqrt{n}(\bar{X}-\mu)}{\sigma} \sim N(0,1) & (\sigma^2 \text{已知}) \\ \dfrac{\sqrt{n}(\bar{X}-\mu)}{S} \sim t(n-1) & (\sigma^2 \text{未知})\end{cases}$

σ^2 的枢轴量 $\dfrac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1)$ (μ 未知).

(2) 两个正态总体 $N(\mu_1,\sigma_1^2)$ $N(\mu_2,\sigma_2^2)$ 情形

$\mu_1-\mu_2$ 的枢轴量

$$\begin{cases}\dfrac{(\bar{X}-\bar{Y})-(\mu_1-\mu_2)}{\sqrt{\dfrac{\sigma_1^2}{n_1}+\dfrac{\sigma_2^2}{n_2}}} \sim N(0,1) & (\sigma_1^2,\sigma_2^2 \text{已知}) \\ \dfrac{(\bar{X}-\bar{Y})-(\mu_1-\mu_2)}{S_W\sqrt{\dfrac{1}{n_1}+\dfrac{1}{n_2}}} \sim t(n_1+n_2-2) & (\sigma_1^2=\sigma_2^2 \text{未知})\end{cases}$$

其中 $S_W^2=\dfrac{(n_1-1)S_1^2+(n_2-1)S_2^2}{n_1+n_2-2}$ $S_W=\sqrt{S_W^2}$

(3) 两个正态总体 $N(\mu_1,\sigma_1^2)$ $N(\mu_2,\sigma_2^2)$ 情形

$\dfrac{\sigma_1^2}{\sigma_2^2}$ 的枢轴量：$\dfrac{S_1^2}{S_2^2}\Big/\dfrac{\sigma_1^2}{\sigma_2^2} \sim F(n_1-1,n_2-1)$ (μ_1,μ_2 未知)

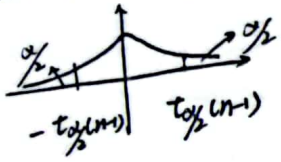
Vx: shilitong1600

对 $\frac{\sqrt{n}(\bar{X}-\mu)}{\sigma} \sim N(0,1)$ (σ^2已知)，置信区间为

$\left[\bar{X}-\frac{\sigma}{\sqrt{n}}z_{\alpha/2}, \bar{X}+\frac{\sigma}{\sqrt{n}}z_{\alpha/2}\right]$

对 $\frac{\sqrt{n}(\bar{X}-\mu)}{S} \sim t(n-1)$ (σ^2未知) 置信区间为

$\left[\bar{X}-\frac{S}{\sqrt{n}}t_{\alpha/2}(n-1), \bar{X}+\frac{S}{\sqrt{n}}t_{\alpha/2}(n-1)\right]$



对 $\frac{(\bar{X}-\bar{Y})-(\mu_1-\mu_2)}{\sqrt{\frac{\sigma_1^2}{n_1}+\frac{\sigma_2^2}{n_2}}}$ (σ_1^2 σ_2^2已知) 置信区间为

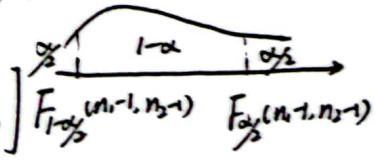
$\left[(\bar{X}-\bar{Y})-z_{\alpha/2}\sqrt{\frac{\sigma_1^2}{n_1}+\frac{\sigma_2^2}{n_2}}, (\bar{X}-\bar{Y})+z_{\alpha/2}\sqrt{\frac{\sigma_1^2}{n_1}+\frac{\sigma_2^2}{n_2}}\right]$

对 $\frac{(\bar{X}-\bar{Y})-(\mu_1-\mu_2)}{S_w\sqrt{\frac{1}{n_1}+\frac{1}{n_2}}}$ ($\sigma_1^2=\sigma_2^2$未知) 置信区间为

$\left[(\bar{X}-\bar{Y})-t_{\alpha/2}(n_1+n_2-2)S_w\sqrt{\frac{1}{n_1}+\frac{1}{n_2}}, (\bar{X}-\bar{Y})+t_{\alpha/2}(n_1+n_2-2)S_w\sqrt{\frac{1}{n_1}+\frac{1}{n_2}}\right]$

对 $\frac{S_1^2}{S_2^2}\Big/\frac{\sigma_1^2}{\sigma_2^2}$ ($\mu_1\mu_2$未知)，置信区间为

$\left[\frac{S_1^2}{S_2^2}\frac{1}{F_{\alpha/2}(n_1-1,n_2-1)}, \frac{S_1^2}{S_2^2}\frac{1}{F_{1-\alpha/2}(n_1-1,n_2-1)}\right]$



0-1分布参数的区间估计

设总体 $X \sim B(1,p)$，参数 p 未知，$X_1 \cdots X_n$ 为样本，样本容量 $n>50$ 时，

$\frac{\sum_{i=1}^{n}X_i-np}{\sqrt{np(1-p)}}$ 近似 $\sim N(0,1)$

$P\left\{-z_{\alpha/2}<\frac{\sum_{i=1}^{n}X_i-np}{\sqrt{np(1-p)}}<z_{\alpha/2}\right\}\approx 1-\alpha$

令 $a=n+z_{\alpha/2}^2$ $b=-(2n\bar{X}+z_{\alpha/2}^2)$ $c=n\bar{X}^2$

参数 p 的置信水平为 $1-\alpha$ 的近似置信区间为

$\left[\frac{-b-\sqrt{b^2-4ac}}{2a}, \frac{-b+\sqrt{b^2-4ac}}{2a}\right]$

Vx: shulitong11666

④ 贝叶斯估计

统计推断中可用的三种信息：总体信息、样本信息、先验信息。所谓先验信息，是指这种信息在"试验之前"就已有的。

贝叶斯公式的密度函数形式：其中 $\pi(\theta|x_1\cdots x_n)$ 称为 θ 的后验密度函数或后验分布。

$$\pi(\theta|x_1\cdots x_n)=\frac{p(x_1,\cdots x_n|\theta)\pi(\theta)}{\int p(x_1\cdots x_n|\theta)\pi(\theta)d\theta}$$

分母部分的作用是使 $\pi(\theta|x_1\cdots x_n)$ 归一化（范围在 $[0,1]$）

人们根据先验信息对参数 θ 已有一个认识，即先验分布 $\pi(\theta)$，通过试验，获得样本。从而对 θ 的先验分布进行调整，调整方法就是贝叶斯公式，调整的结果就是后验分布 $\pi(\theta|x_1\cdots x_n)$。后验分布是总体、样本、先验三种信息的综合，获得后验分布使人们对 θ 的认识又进了一步。可看出，获得样本的效果是把我们对 θ 的认识 $\pi(\theta)$ 调整到 $\pi(\theta|x_1\cdots x_n)$，所以对 θ 的统计推断就应建立在后验分布 $\pi(\theta|x_1\cdots x_n)$ 的基础上。

如果人们对某事件的先验分布一无所知，可用区间 $(0,1)$ 上的均匀分布作为先验分布，即 $\pi(\theta)=\begin{cases}1, & 0<\theta<1\\ 0, & others\end{cases}$

先验分布的确定一般选用 β 分布族

$$\pi(\theta)=\frac{\Gamma(a+b)}{\Gamma(a)\Gamma(b)}\theta^{a-1}(1-\theta)^{b-1},\quad 0\le\theta\le 1,\ a>0,\ b>0$$

变量为 θ，参数为 a,b。

注：$\Gamma(s)=\int_0^\infty x^{s-1}e^{-x}dx,\ s>0$，$\Gamma(n+1)=n!$

$$B(p,q)=\int_0^1 x^{p-1}(1-x)^{q-1}dx,\ p>0,\ q>0$$

$$B(p,q)=\frac{\Gamma(p)\Gamma(q)}{\Gamma(a+b)},\ p>0,\ q>0$$

贝塔分布

$$f(x;\alpha,\beta)=\frac{x^{\alpha-1}(1-x)^{\beta-1}}{\int_0^1 u^{\alpha-1}(1-u)^{\beta-1}du}=\frac{\Gamma(\alpha+\beta)}{\Gamma(\alpha)\Gamma(\beta)}x^{\alpha-1}(1-x)^{\beta-1}$$

$$E(X)=\frac{\alpha}{\alpha+\beta}\qquad D(X)=\frac{\alpha\beta}{(\alpha+\beta)^2(\alpha+\beta+1)}$$

先验分布与后验分布称为参数 θ 的共轭先验分布

定义 使后验密度 $\pi(\theta|x)$ 达到最大的值 θ_{MD} 称为最大后验估计；后验分布的中位数 $\hat\theta_{ME}$ 称为后验中位数估计；后验分布的期望值 $\hat\theta_E$ 称为 θ 的后验期望值估计。三者都被称为贝叶斯估计，记为 $\hat\theta_B$

$\hat\theta_E$ 比 θ_{MD} 更合适

贝叶斯估计的误差

设 $\hat\theta$ 是 θ 的一个贝叶斯估计，在样本给定后，$\hat\theta$ 是一个数，评价一个贝叶斯估计的误差的最好方式是 [illegible] 用 $\hat\theta$ 对 θ 的后验

均方差或平方根来度量.

设参数θ的后验分布为$\pi(\theta|x)$，贝叶斯估计为$\hat{\theta}$.则$\hat{\theta}$的后验期望 $MSE(\hat{\theta}|x)=E^{\theta|x}(\theta-\hat{\theta})^2$.称为$\hat{\theta}$的后验均方差.其平方根为后验标准差.

经推导 常取后验均值θ_E作为贝叶斯估计值.

区间估计

定义：参数θ的后验分布为$\pi(\theta|x)$对给定的样本X和概率$1-\alpha$ $(0<\alpha<1)$，若存在这样的两个统计量$\hat{\theta}_L=\hat{\theta}_L(x)$和$\hat{\theta}_U=\hat{\theta}_U(x)$使得 $P\{\hat{\theta}_L\le\theta\le\hat{\theta}_U|x\}\ge1-\alpha$

则称区间$[\hat{\theta}_L,\hat{\theta}_U]$为参数的可信水平为$1-\alpha$贝叶斯可信区间.

而$P(\theta\ge\hat{\theta}_L|x)\ge1-\alpha$的$\hat{\theta}_L$称为$\theta$的$1-\alpha$(单侧)可信下限.

$P(\theta\le\hat{\theta}_U|x)\ge1-\alpha$的$\hat{\theta}_U$称为$\theta$的$1-\alpha$(单侧)可信上限.

贝叶斯决策

贝叶斯统计的第四类信息：损失函数

决策三要素：状态集$\Theta=\{\theta\}$(行) 行动集$A=\{a\}$(列)

收益函数$Q(\theta,a)$

损失函数$L(\theta,a)=\max\limits_{a\in A}Q(\theta,a)-Q(\theta,a)$

损失函数下的悲观准则

对每个行动a选出最大损失值 记为$\max\limits_{\theta\in\Theta}L(\theta,a)$，$a\in A$(每列max)

$\max\limits_{a\in A}\max\limits_{\theta\in\Theta}L(\theta,a)=\max\limits_{\theta\in\Theta}L(\theta,a')$ (每列max中最小的一个)

称a'为悲观准则下的最优行动

Vx:shulitong1666

方差分析的解题过程.

$H_0: \mu_1=\mu_2=\mu_3$　　$H_1: \mu_1\ \mu_2\ \mu_3$ 不完全相等.

总偏差平方和 $Q=\sum_{i=1}^{r}\sum_{j=1}^{n_i}(x_{ij}-\bar{x})^2=\sum_{i=1}^{r}\sum_{j=1}^{n_i}x_{ij}^2-n\bar{x}^2=(n-1)s^2$

组间偏差平方和 $Q_A=\sum_{i=1}^{r}n_i(\bar{x}_i-\bar{x})^2=\sum_{i=1}^{r}n_i\bar{x}_i^2-n\bar{x}^2$

组内偏差平方和 $Q_e=\sum_{i=1}^{r}\sum_{j=1}^{n_i}(x_{ij}-\bar{x}_i)^2=\sum_{i=1}^{r}(n_i-1)s_i^2$

其中 $\bar{x}=\frac{1}{n}\sum_{i=1}^{r}\sum_{j=1}^{n_i}x_{ij}$　　$s_i^2=\frac{1}{n_i-1}\sum_{j=1}^{n_i}(x_{ij}-\bar{x}_i)^2$

$\bar{x}_i=\frac{1}{n_i}\sum_{j=1}^{n_i}x_{ij}$,　　$s^2=\frac{1}{n-1}\sum_{i=1}^{r}\sum_{j=1}^{n_i}(x_{ij}-\bar{x})^2$

$F=\frac{(n-r)Q_A}{(r-1)Q_e}\sim F(r-1,n-r)$

若 $\frac{(n-r)Q_A}{(r-1)Q_e}>F_{1-\alpha}(r-1,n-r)$ 则拒绝 H_0. 认为有显著关系

线性回归

在显著水平 α 下检验假设 $H_0: \beta_1=0$ 或 y 与 x 线性关系显著

$F=\frac{U_R/k}{Q_e/(n-k-1)}\sim F(k,n-k-1)$ (对 $\beta_0\ \beta_1$ 来说 $k=1$)

若 $F>F_{1-\alpha}(k,n-k-1)$, 则拒绝 H_0. 即 y 与 x 线性关系显著

其中 $U_R=\sum_{t=1}^{n}(\hat{y}_t-\bar{y})^2=\hat{\beta}_1^2L_{xx}=\frac{L_{xy}^2}{L_{xx}}=\hat{\beta}_1L_{xy}$

$Q_e=L_{yy}-U_R=L_{yy}-\frac{L_{xy}^2}{L_{xx}}=L_{yy}(1-r^2)$

关于 β 的置信区间.

$\hat{\beta}_0\sim N(\beta_0,\frac{\sigma^2}{n}+\frac{\sigma^2\bar{x}^2}{L_{xx}})$　　$\hat{\beta}_1\sim N(\beta_1,\frac{\sigma^2}{L_{xx}})$

若 σ^2 未知 ($\varepsilon\sim N(0,\sigma^2)$)

$\frac{(n-k-1)\hat{\sigma}_e^2}{\sigma^2}\sim\chi^2(n-k-1)$. 上面两式组合成下面和

$\because\frac{Q_e}{\sigma^2}\sim\chi^2(n-k-1)$. 且 $Q_e=(n-k-1)\hat{\sigma}_e^2$

$Q_e=\sum_{t=1}^{n}(y_t-\hat{Y}_t)^2$

$\therefore\frac{(n-k-1)\hat{\sigma}_e^2}{\sigma^2}\sim\chi^2(n-k-1)$.

lx · shulitong1168

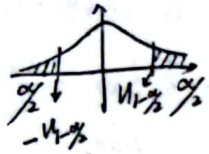
参数检验.

一个总体(默认下分位点)

① 对 μ. 而 σ^2 已知

$H_0: \mu=\mu_0 \quad H_1: \mu\neq\mu_0$

$\frac{\bar{X}-\mu_0}{\sigma/\sqrt{n}} \sim N(0,1)$



拒绝域 $W=\left\{\left|\frac{\bar{X}-\mu_0}{\sigma/\sqrt{n}}\right| \geq u_{1-\frac{\alpha}{2}}\right\}$

$H_0: \mu\geq\mu_0 \quad H_1: \mu<\mu_0$



拒绝域 $W=\left\{\frac{\bar{X}-\mu_0}{\sigma/\sqrt{n}} \leq u_\alpha\right\}$

$H_0: \mu\leq\mu_0 \quad H_1: \mu>\mu_0$



$W=\left\{\frac{\bar{X}-\mu_0}{\sigma/\sqrt{n}} \geq u_{1-\alpha}\right\}$

若 σ^2 未知.

则 u 换为 t.

课后习题 14. 15. 16. 17

为皮尔逊 χ^2 检验法.

18, 19, 20 为独立性检验.

秩和检验法.

$n_1, n_2 < 10$

① 排序

② R_1、R_2 = Σ秩

③ 由 n_1, n_2 查 t_1, t_2

④ $W=\{R_1<t_1$ 或 $R_1>t_2\}$.

$n_1, n_2 > 10$

① 排序 ② R_1、R_2 = Σ秩

③ $u_1=\frac{R_1-\mu_1}{\sigma_1} \sim N(0,1)$

$\mu_1=\frac{n_1(n_1+n_2+1)}{2}$

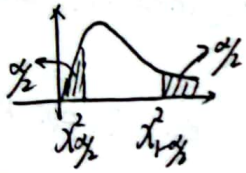
$\sigma_1^2=\frac{n_1n_2(n_1+n_2+1)}{12}$

④ $W=\{|u_1| \geq u_{\frac{\alpha}{2}}\}$

② 对 σ^2. 而 μ 已知.

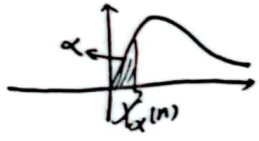
$H_0: \sigma^2=\sigma_0^2 \quad H_1: \sigma^2\neq\sigma_0^2$

$\frac{1}{\sigma^2}\sum_{i=1}^{n}(x_i-\mu)^2 \sim \chi^2(n)$



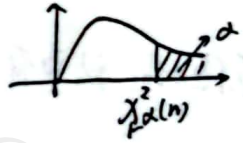
拒绝域 $W=\left\{\frac{1}{\sigma^2}\sum_{i=1}^{n}(x_i-\mu)^2 \leq \chi^2_{\frac{\alpha}{2}}(n)$ 或 $\frac{1}{\sigma^2}\sum_{i=1}^{n}(x_i-\mu)^2 \geq \chi^2_{1-\frac{\alpha}{2}}(n)\right\}$.

$H_0: \sigma^2\geq\sigma_0^2 \quad H_1: \sigma^2<\sigma_0^2$



$W=\left\{\frac{1}{\sigma^2}\sum_{i=1}^{n}(x_i-\mu)^2 \leq \chi^2_{\alpha}(n)\right\}$.

$H_0: \sigma^2\leq\sigma_0^2 \quad H_1: \sigma^2>\sigma_0^2$



$W=\left\{\frac{1}{\sigma^2}\sum_{i=1}^{n}(x_i-\mu)^2 \geq \chi^2_{1-\alpha}(n)\right\}$.

对 σ^2. 而 μ 未知

$H_0: \sigma^2=\sigma_0^2 \quad H_1: \sigma^2\neq\sigma_0^2$

$\frac{(n-1)S^2}{\sigma_0^2} \sim \chi^2(n-1)$ $W=\left\{\frac{(n-1)S^2}{\sigma_0^2} \leq \chi^2_{\frac{\alpha}{2}}(n-1)$ 或 $\frac{(n-1)S^2}{\sigma_0^2} > \chi^2_{1-\frac{\alpha}{2}}(n-1)\right\}$

$H_0: \sigma^2\geq\sigma_0^2 \quad H_1: \sigma^2<\sigma_0^2$

$W=\left\{\frac{(n-1)S^2}{\sigma_0^2} \leq \chi^2_{\alpha}(n-1)\right\}$.

$H_0: \sigma^2\leq\sigma_0^2 \quad H_1: \sigma^2>\sigma_0^2$

$W=\left\{\frac{(n-1)S^2}{\sigma_0^2} \geq \chi^2_{1-\alpha}(n-1)\right\}$

VX: shulitong1165

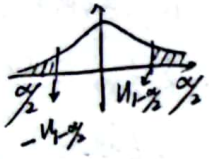
参数检验.

一个总体(默认下为估点)

① 对 μ. 而 σ^2 已知

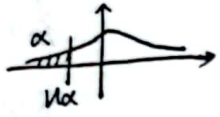
$H_0: \mu=\mu_0 \quad H_1: \mu\neq\mu_0$

$\frac{\bar{X}-\mu_0}{\sigma/\sqrt{n}} \sim N(0,1)$



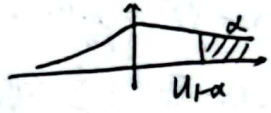
拒绝域 $W=\left\{\left|\frac{\bar{X}-\mu_0}{\sigma/\sqrt{n}}\right| \geq u_{1-\alpha/2}\right\}$

$H_0: \mu\geq\mu_0 \quad H_1: \mu<\mu_0$



拒绝域 $W=\left\{\frac{\bar{X}-\mu_0}{\sigma/\sqrt{n}} \leq u_\alpha\right\}$

$H_0: \mu\leq\mu_0 \quad H_1: \mu>\mu_0$



$W=\left\{\frac{\bar{X}-\mu_0}{\sigma/\sqrt{n}} \geq u_{1-\alpha}\right\}$

若 σ^2 未知.

则 t 对换为 t.

课后习题 14. 15. 16. 17 为皮尔逊 χ^2 检验.

18. 19. 20 为 独立性检验.

秩和检验.

n_1、n_2 <10

① 排序

② R_1、R_2 = Σ秩

③ 由 n_1 n_2 查 t_1 t_2

④ $W=\{R_1<t_1$ 或 $R_1>t_2\}$.

n_1 n_2 >10

① 排序 ② R_1、R_2 = Σ秩

③ $u_1=\frac{R_1-\mu_1}{\sigma_1}\sim N(0,1)$

$\mu_1=\frac{n_1(n_1+n_2+1)}{2}$

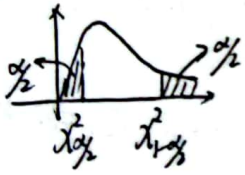
$\sigma_1^2=\frac{n_1n_2(n_1+n_2+1)}{12}$

④ $W=\{|u_1|\geq u_{\alpha/2}\}$

② 对 σ^2. 而 μ 已知.

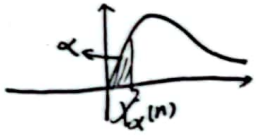
$H_0: \sigma^2=\sigma_0^2 \quad H_1: \sigma^2\neq\sigma_0^2$

$\frac{1}{\sigma^2}\sum_{i=1}^{n}(x_i-\mu)^2 \sim \chi^2(n)$



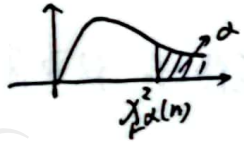
拒绝域 $W=\left\{\frac{1}{\sigma^2}\sum_{i=1}^{n}(x_i-\mu)^2 \leq \chi^2_{\alpha/2}(n)$ 或 $\frac{1}{\sigma^2}\sum_{i=1}^{n}(x_i-\mu)^2 \geq \chi^2_{1-\alpha/2}(n)\right\}$.

$H_0: \sigma^2\geq\sigma_0^2 \quad H_1: \sigma^2<\sigma_0^2$



$W=\left\{\frac{1}{\sigma^2}\sum_{i=1}^{n}(x_i-\mu)^2 \leq \chi^2_{\alpha}(n)\right\}$.

$H_0: \sigma^2\leq\sigma_0^2 \quad H_1: \sigma^2>\sigma_0^2$



$W=\left\{\frac{1}{\sigma^2}\sum_{i=1}^{n}(x_i-\mu)^2 \geq \chi^2_{1-\alpha}(n)\right\}$.

对 σ^2、而 μ 未知

$H_0: \sigma^2=\sigma_0^2 \quad H_1: \sigma^2\neq\sigma_0^2$

$\frac{(n-1)S^2}{\sigma_0^2} \sim \chi^2(n-1)$ $W=\left\{\frac{(n-1)S^2}{\sigma_0^2} \leq \chi^2_{\alpha/2}(n-1)$ 或 $\frac{(n-1)S^2}{\sigma_0^2} > \chi^2_{1-\alpha/2}(n-1)\right\}$

$H_0: \sigma^2\geq\sigma_0^2 \quad H_1: \sigma^2<\sigma_0^2$

$W=\left\{\frac{(n-1)S^2}{\sigma_0^2} \leq \chi^2_{\alpha}(n-1)\right\}$.

$H_0: \sigma^2\leq\sigma_0^2 \quad H_1: \sigma^2>\sigma_0^2$

$W=\left\{\frac{(n-1)S^2}{\sigma_0^2} \geq \chi^2_{\alpha}(n-1)\right\}$

Vx: shulitong1166

$$X=\begin{bmatrix}1 & x_1\\ 1 & x_2\\ \vdots & \vdots\\ 1 & x_n\end{bmatrix}\quad X^T=\begin{bmatrix}1 & 1 & \cdots & 1\\ x_1 & x_2 & \cdots & x_n\end{bmatrix}$$

$$L=X^TX=\begin{bmatrix}1 & 1 & \cdots & 1\\ x_1 & x_2 & \cdots & x_n\end{bmatrix}\begin{bmatrix}1 & x_1\\ 1 & x_2\\ \vdots & \vdots\\ 1 & x_n\end{bmatrix}=\begin{bmatrix}n & n\bar{x}\\ n\bar{x} & \sum_{i=1}^{n}x_i^2\end{bmatrix}$$

$$L^{-1}=\frac{1}{|L|}L^T=\frac{1}{L_{xx}}\begin{bmatrix}\frac{1}{n}\sum_{i=1}^{n}x_i^2 & -\bar{x}\\ -\bar{x} & 1\end{bmatrix}$$

$Y=AX+a$, $Y\sim N(A\theta+a,\ A\Sigma A^T)$.

$$\beta=\begin{bmatrix}\hat{\beta}_0\\ \hat{\beta}_1\end{bmatrix}\sim N\left(\begin{bmatrix}\beta_0\\ \beta_1\end{bmatrix},\ \sigma^2L^{-1}\right)$$

求 $\hat{\beta}_0$：

$$[1\ 0]\begin{bmatrix}\hat{\beta}_0\\ \hat{\beta}_1\end{bmatrix}=\hat{\beta}_0\sim N\left([1,0]\begin{bmatrix}\beta_0\\ \beta_1\end{bmatrix},\ [1,0]\frac{\sigma^2}{L_{xx}}\begin{bmatrix}\frac{1}{n}\sum_{i=1}^{n}x_i^2 & -\bar{x}\\ -\bar{x} & 1\end{bmatrix}\begin{bmatrix}1\\ 0\end{bmatrix}\right)$$

$$\Rightarrow \hat{\beta}_0\sim N\left(\beta_0,\ \sigma^2\left(\frac{1}{n}+\frac{\bar{x}^2}{L_{xx}}\right)\right)$$

求 $\hat{\beta}_1$：

$$[0,1]\begin{bmatrix}\hat{\beta}_0\\ \hat{\beta}_1\end{bmatrix}=\hat{\beta}_1\sim N\left([0,1]\begin{bmatrix}\beta_0\\ \beta_1\end{bmatrix},\ [0,1]\frac{\sigma^2}{L_{xx}}\begin{bmatrix}\frac{1}{n}\sum_{i=1}^{n}x_i^2 & -\bar{x}\\ -\bar{x} & 1\end{bmatrix}\begin{bmatrix}1\\ 0\end{bmatrix}\right)$$

$$\Rightarrow \hat{\beta}_1\sim N\left(\beta_1,\ \sigma^2\frac{1}{L_{xx}}\right)$$

求 $\hat{\beta}_0-\hat{\beta}_1$

$$[1,-1]\begin{bmatrix}\hat{\beta}_0\\ \hat{\beta}_1\end{bmatrix}=\hat{\beta}_0-\hat{\beta}_1\sim N\left([1,-1]\begin{bmatrix}\beta_0\\ \beta_1\end{bmatrix},\ [1,-1]\frac{\sigma^2}{L_{xx}}\begin{bmatrix}\frac{1}{n}\sum_{i=1}^{n}x_i^2 & -\bar{x}\\ -\bar{x} & 1\end{bmatrix}\begin{bmatrix}1\\ -1\end{bmatrix}\right)$$

$$\hat{\beta}_0-\hat{\beta}_1\sim N\left((\beta_0-\beta_1),\ \sigma^2\left(\frac{1}{n}+\frac{(\bar{x}+1)^2}{L_{xx}}\right)\right)$$

Vx: shulitong1666